

RAPPORT TECHNIQUE

Analyse des retards de livraison et optimisation de la satisfaction client

Dataset Olist — Brazilian E-Commerce Public Dataset

Certificat : Data Analysis

Auteur : Mansouratou ZAKARI

Juin 2026

Sommaire

1. Description du problème
 2. Description des données
 3. Méthodologie
 4. Langages et outils utilisés
 5. Résultats obtenus
 6. Analyse des erreurs
 7. Limites du projet
 8. Perspectives d'amélioration
- Conclusion

1. Description du problème

Une plateforme de e-commerce brésilienne subit une baisse continue de sa note de satisfaction client. L'examen des retours utilisateurs et des indicateurs internes a permis d'identifier les retards de livraison comme la cause principale du désabonnement et de la dégradation de l'image de marque.

La question centrale de ce projet est la suivante : comment identifier précisément les maillons faibles de la chaîne de transport — qu'il s'agisse d'une région, d'une catégorie de produit ou d'une caractéristique logistique — afin de réduire les délais et d'améliorer durablement la satisfaction client ?

L'objectif est de concevoir un pipeline d'analyse de bout en bout permettant de monitorer les délais de livraison réels par rapport aux promesses faites aux clients, à travers un tableau de bord interactif et exploitable par les équipes opérationnelles.

Objectifs spécifiques

- Calculer les indicateurs de performance clés : délai moyen de livraison, taux de retard, écart à l'estimation.
- Identifier les corrélations entre le prix du fret, le poids du colis et la rapidité de livraison.
- Construire un modèle de données optimisé dans Power BI, structuré en schéma en étoile.
- Fournir des recommandations stratégiques exploitables, par exemple sur le choix des transporteurs par région.

2. Description des données

Le projet s'appuie sur le Brazilian E-Commerce Public Dataset, mis à disposition par Olist sur Kaggle. Il s'agit d'un ensemble de données tabulaires réelles et anonymisées couvrant environ 99 441 commandes passées entre 2016 et 2018 sur la marketplace Olist.

Le dataset est réparti sur 9 fichiers CSV interconnectés par des identifiants communs (order_id, customer_id, product_id, seller_id) :

- olist_orders_dataset.csv — informations sur les commandes et les dates clés (achat, approbation, expédition, livraison, estimation)
- olist_order_items_dataset.csv — détail des articles commandés, prix et frais de port
- olist_products_dataset.csv — caractéristiques produit (poids, dimensions, catégorie)
- olist_customers_dataset.csv — localisation des clients (ville, état)
- olist_sellers_dataset.csv — localisation des vendeurs
- olist_order_reviews_dataset.csv — notes et commentaires de satisfaction
- olist_geolocation_dataset.csv — coordonnées géographiques par code postal
- olist_order_payments_dataset.csv — modes et montants de paiement

- `product_category_name_translation.csv` — traduction des catégories de produits en anglais

La variable cible de l'analyse est le délai de livraison réel, calculé comme la différence entre la date de réception par le client (`order_delivered_customer_date`) et la date d'achat (`order_purchase_timestamp`). Cette variable est mise en perspective avec la date de livraison estimée annoncée au client (`order_estimated_delivery_date`), afin de déterminer si une commande est en retard.

3. Méthodologie

La démarche suit une approche structurée en plusieurs étapes successives, de la compréhension du problème jusqu'au déploiement d'un tableau de bord interactif.

1. Compréhension du problème et exploration de la documentation du dataset.
2. Chargement des données dans un environnement Google Colab via l'API kagglehub et la librairie Pandas.
3. Analyse exploratoire des données (EDA) : détection des valeurs manquantes, des doublons et des valeurs extrêmes sur l'ensemble des tables.
4. Nettoyage et prétraitement : conversion des types de données (dates, nombres), traitement des valeurs nulles, jointures entre les tables sources.
5. Construction d'un pipeline ETL calculant les indicateurs clés (délai réel, écart à l'estimation, statut de retard) et exportant un jeu de données consolidé.
6. Construction du tableau de bord Power BI : modélisation en schéma en étoile, création de mesures DAX personnalisées, conception des visualisations et filtres interactifs.
7. Interprétation des résultats et formulation de recommandations stratégiques.
8. Analyse des erreurs et des limites du projet.
9. Documentation et préparation de la présentation finale.

Pipeline ETL

Le pipeline Python repose sur Pandas pour la manipulation des données. Les étapes clés incluent la conversion des colonnes de dates au format `datetime`, le calcul du délai réel et de l'écart à l'estimation en jours, puis la jointure successive des tables `order_items`, `products`, `customers`, `sellers` et `reviews` autour de la table `orders`. Le résultat final, exporté sous forme de fichier CSV unique (`olist_final.csv`), constitue la table de faits du modèle Power BI.

Modélisation Power BI

Le tableau de bord repose sur un schéma en étoile : une table de faits centrale (`olist_final`) contenant les métriques de délai, de fret et de satisfaction, reliée à des dimensions Date, Produit, Géographie et Vendeur. Une table calendrier dédiée (`Dim_Calendrier`) a été générée par DAX pour permettre les analyses temporelles et le tri chronologique correct des mois.

4. Langages et outils utilisés

- Python (Pandas, Matplotlib, Seaborn) — nettoyage des données et analyse exploratoire
- Google Colab — environnement d'exécution du notebook, sans configuration locale requise
- Power BI Desktop — modélisation des données et construction du tableau de bord interactif
- DAX (Data Analysis Expressions) — mesures personnalisées (taux de retard, délai moyen, score moyen)
- Git et GitHub — gestion de version et hébergement du code source et de la documentation

5. Résultats obtenus

L'analyse du jeu de données complet (97 007 commandes livrées après nettoyage) fait apparaître les indicateurs de performance suivants :

Indicateur	Valeur
Commandes totales	97 007
Délai moyen de livraison	12,1 jours
Délai médian	10,0 jours
Taux de retard	6,8 %
Écart moyen à l'estimation	-11,9 jours (avance)
Note moyenne (livraison à l'heure)	4,3 / 5
Note moyenne (livraison en retard)	2,3 / 5

Le résultat le plus significatif du projet concerne la relation directe entre le respect des délais et la satisfaction client : les commandes livrées à l'heure obtiennent une note moyenne de 4,3 sur 5, contre seulement 2,3 sur 5 pour les commandes livrées en retard, soit un écart de deux points sur l'échelle de satisfaction.

Tableau de bord — KPIs de livraison Olist



Figure 1 — Vue globale des indicateurs clés et impact du retard sur la satisfaction client

Analyse géographique

L'analyse par état brésilien révèle une disparité marquée entre les régions. Les états du Nord et du Nord-Est concentrent les délais les plus longs et les taux de retard les plus élevés, comme le montre le tableau suivant pour les huit états les plus affectés.

État	Délai moyen (j)	Taux de retard	Nb commandes
RR	28,98	12 %	41
AP	26,73	3 %	67
AM	25,99	3 %	145
AL	24,04	21 %	397
PA	23,32	11 %	946
MA	21,12	17 %	717
SE	21,03	15 %	335
CE	20,82	14 %	1 279

L'état d'Alagoas (AL) se distingue particulièrement : avec un délai moyen de 24 jours et un taux de retard de 21 %, il combine à la fois un délai élevé et une forte proportion de commandes en

retard. L'état du Ceará (CE), bien que moins critique en proportion, représente un volume de 1 279 commandes, ce qui en fait une priorité en termes d'impact global.

Analyse régionale des délais et retards





Figure 2 — Délai moyen par état et évolution temporelle des délais

Analyse produit

Le croisement entre les caractéristiques produit et les délais de livraison montre que certaines catégories de produits, notamment les meubles et équipements volumineux, affichent des délais sensiblement supérieurs à la moyenne. La relation entre le poids du colis et le délai de livraison reste cependant modérée, suggérant que la distance géographique et la disponibilité du transporteur jouent un rôle plus déterminant que les caractéristiques physiques du produit.

Impact des caractéristiques produit sur la livraison

Top 10 catégories les plus lentes à livrer



Relation entre poids du colis et délai




Figure 3 — Délai moyen par catégorie de produit et relation poids / délai

Recommandations stratégiques

- Prioriser la renégociation des contrats de transport ou le changement de transporteur pour les états AL, MA, CE et PA, qui combinent volume significatif et taux de retard élevé.
- Mettre en place une alerte opérationnelle automatique lorsque le délai estimé dépasse 20 jours pour une commande, afin d'anticiper la communication avec le client.
- Étudier la possibilité d'entrepôts relais dans le Nord-Est du Brésil afin de réduire la distance moyenne de livraison vers ces régions.
- Suivre en continu l'indicateur de satisfaction par tranche de délai pour valider l'impact des actions correctives mises en place.

6. Analyse des erreurs

La phase de construction du pipeline a permis d'identifier plusieurs erreurs caractéristiques de l'ingestion de données tabulaires hétérogènes.

- Format des nombres décimaux : les colonnes `delai_reel_jours`, `ecart_estimation_jours` et `fret_total` ont été importées par Power BI comme du texte, en raison de la présence du point comme séparateur décimal. La correction a nécessité un remplacement du séparateur dans Power Query avant la conversion du type de données en nombre décimal.
- Valeurs manquantes : 1 386 lignes ne disposaient pas de traduction de catégorie de produit en anglais, et 16 lignes ne disposaient pas de fiche technique produit (poids,

dimensions). Ces valeurs ont été remplacées respectivement par la valeur "unknown" et par zéro, sans impact significatif sur les agrégations globales étant donné leur faible proportion.

- Comparaison de types incompatibles : la mesure DAX de taux de retard a initialement échoué car la colonne booléenne `est_en_retard` était également importée sous forme de texte, empêchant la comparaison directe avec la valeur logique `TRUE()`.

Ces erreurs ont toutes été résolues en amont, au niveau de Power Query, ce qui garantit la cohérence des types de données pour l'ensemble des mesures du tableau de bord.

7. Limites du projet

- Le dataset couvre uniquement la période 2016-2018 et ne reflète pas nécessairement les conditions logistiques actuelles au Brésil.
- Aucune information directe sur l'identité ou la performance des transporteurs n'est disponible ; seule la localisation du vendeur est connue, ce qui limite la granularité des recommandations relatives au choix de transporteur.
- Les coordonnées géographiques issues du fichier de géolocalisation sont approximées au niveau du code postal et non de l'adresse exacte, introduisant une marge d'erreur dans les analyses spatiales fines.
- Certains états affichent un nombre de commandes très faible (par exemple 41 commandes pour l'état de Roraima), ce qui fragilise la robustesse statistique des indicateurs calculés à cette échelle.
- L'analyse établit une corrélation forte entre retard et satisfaction, mais ne permet pas d'isoler un lien de causalité strict, d'autres facteurs (qualité du produit, service client) pouvant également influencer la note laissée par le client.

8. Perspectives d'amélioration

- Développer un modèle prédictif de risque de retard au moment de la commande, permettant une alerte précoce avant l'expédition.
- Enrichir l'analyse avec des données de transporteur si elles deviennent disponibles, afin de comparer directement leurs performances respectives.
- Déployer le tableau de bord sur Power BI Service ou convertir l'analyse en application Streamlit pour permettre un accès public et une démonstration en ligne.
- Mettre à jour le pipeline pour intégrer des données plus récentes si elles deviennent disponibles, afin de suivre l'évolution de la situation dans le temps.

Conclusion

Ce projet a permis de construire un pipeline d'analyse complet, depuis l'ingestion brute des données Olist jusqu'à un tableau de bord Power BI interactif et structuré. L'analyse confirme l'hypothèse de départ : le retard de livraison constitue bien le facteur principal de dégradation

de la satisfaction client, avec un écart de notation de près de deux points entre commandes à l'heure et commandes en retard. Les disparités régionales identifiées, en particulier dans le Nord et le Nord-Est du Brésil, offrent des pistes d'action concrètes et priorisables pour les équipes logistiques de la plateforme.